ANALIZA DATELOR
Analiza componentelor principale

Facultatea: Cibernetică, statistică și informatică economică
Specializarea: Cibernetică economică
Licență, an 3

Conf. Univ. Dr. Zamfir Ionela-Cătălina
ionela.zamfir@csie.ase.ro

București, 2026

CUPRINS

A. Concepte specifice ale analizei datelor

B. Definirea și scopul ACP

C. Modelul matematic

D. Proprietățile componentelor principale

E. Criterii de alegere a numărului de componente

F. Matricea factor și interpretare

G. Exemplu numeric – set de date cu companii

A. Concepte specifice ale analizei datelor

- Ce sunt datele?
- Clasificarea datelor:
  - dpdv al naturii lor: cantitative / calitative (scale de măsurare a datelor?)

    R: ordinală (ex: categoria de venit), nominală (ex: profesia), interval, raport (nr.)
  - dpdv al modului de obținere: experimental / observațional
  - dpdv al tipului lor: profil / serii de timp / panel
- Colectivitate – populație statistică – eșantion ?

R: entități cu existență fizică, concretă – obs. reale și virtuale – parte din colectivitate

- Parametru – estimator – estimație ?

R: mărime necunoscută niciodată (ex: media unei pop statistice) – funcție construită pentru aproximarea parametrului – un <u>număr</u> obținut din evaluarea estimatorului pe eșantionul de date

B. Definirea și scopul ACP

n variabile inițiale: $X_1, X_2, \dots, X_n \xrightarrow{ACP}$ k componente principale $Z_1, Z_2, \dots, Z_n$, cu $k \ll n$

- Matricea inițială de date: n variabile, T observații

  Scop ACP: sintetizarea informațională – reducerea dimensionalității, eliminarea redundanței informaționale

- Componentele principale sunt agregați (combinații liniare) obținuți din variabilele inițiale care, prin construcția loc, preiau maxim din informația din cele n variabile inițiale și sunt necorelați doi câte doi.

- $Z = f(X_1, X_2, \dots, X_n)$ – funcție liniară

- Măsuri ale cantității de informație:

$$VT = \sum_{i=1}^{n} \sigma_{x_i}^2 \qquad VG = |\Sigma|$$

C. Modelul matematic

$$Z = f(X_1, X_2, \dots, X_n)$$

$$Z = \alpha_1 X_1 + \alpha_2 X_2 + \cdots + \alpha_n X_n = \alpha^t X$$

$$\text{unde: } \alpha = \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \dots \\ \alpha_n \end{pmatrix}, \text{ iar } X = \begin{pmatrix} X_1 \\ X_2 \\ \dots \\ X_n \end{pmatrix}$$

Obs: În construirea componentelor principale Z trebuie să îi determinăm pe $\alpha_1, \alpha_2, \dots, \alpha_n$, astfel încât Z să preia maxim de informație (sau *varianța componentei Z să fie maximă*).

$E(Z) = E(\alpha^t X) = \alpha^t E(X) = 0$, variabilele X fiind standardizate

$$Var(Z) = E\left[\left(Z - E(Z)\right)^2\right] = E\left[\left(Z - E(Z)\right)\left(Z - E(Z)\right)^t\right] = E[Z \cdot Z^t]$$
$$= E(\alpha^t X X^t \alpha) = \alpha^t E(XX^t)\alpha$$

știm că: $E(XX^t) = cov(X, X)$, de unde rezultă că: $Var(Z) = \alpha^t \Sigma \alpha$

C. Modelul matematic

Astfel, modelul de optimizare este:

$$\begin{cases} \max\limits_{\alpha} \mathrm{Var}(Z) = \alpha^t \Sigma \alpha \\ \alpha^t \alpha = 1 \end{cases}$$

Lagrangeanul este: $\mathcal{L}(\alpha, \lambda) = \alpha^t \Sigma \alpha - \lambda(\alpha^t \alpha - 1)$, iar condițiile de optim sunt:

$$\begin{cases} \dfrac{\partial \mathcal{L}(\alpha, \lambda)}{\partial \alpha^t} = 0 \\ \dfrac{\partial \mathcal{L}(\alpha, \lambda)}{\partial \lambda} = 0 \end{cases} \overset{\text{soluția}}{\Longrightarrow} \begin{cases} 2\Sigma\alpha - 2\lambda\alpha = 0 \\ \alpha^t \alpha - 1 = 0 \end{cases}$$

Deci: $\Sigma\alpha = \lambda\alpha \Rightarrow \alpha$ este vector propriu al matricii de covarianță, unul din vectorii proprii asociați valorii proprii λ, iar $\mathrm{Var}(Z) = \lambda$.

În felul acesta se deduc cele n componente principale, prima componentă (Z_1) preia maxim din informația variabilelor X, a doua componentă preia maxim din informația din X nepreluată de prima componentă, și așa mai departe.

D. Proprietățile componentelor principale

1. Cele n componente principale conservă integral informația din cele n variabile inițiale în sens de:

- varianță totală: $V_T^Z = V_T^X \Leftrightarrow \sum_{i=1}^n \lambda_i = \sum_{i=1}^n \sigma_i^2$
- varianță generalizată: $V_G^Z = V_G^X \Leftrightarrow |\Lambda| = |\Sigma|$, unde matricea

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & 0 \cdots & \lambda_n \end{pmatrix}$$

2. Prin modul de construire a componentelor principale, acestea sunt necorelate 2 câte 2 (nu există suprapunere/redundanță informațională)

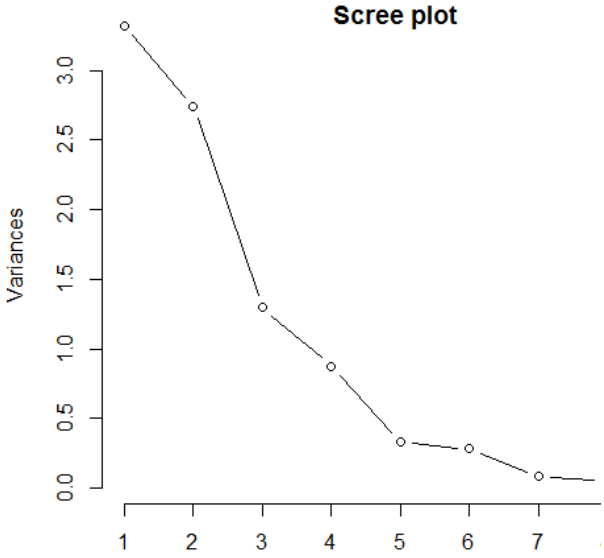
$$\mathrm{cov}(Z_i, Z_j) = 0, \forall i \neq j$$

3. Componentele principale au varianță maximală descrescătoare:

$$\lambda_1 > \lambda_2 > \cdots > \lambda_n$$
$$\mathrm{Var}(Z_1) > \mathrm{Var}(Z_2) > \cdots > \mathrm{Var}(Z_n)$$
$$\mathrm{Inf}(Z_1) > \mathrm{Inf}(Z_2) > \cdots > \mathrm{Inf}(Z_n)$$

E. Criterii de alegere a numărului de componente

1. Criteriul pantei



2. Criteriul Kaiser

$$\lambda > 1$$

3. Criteriul procentului de acoperire

$$p_k = \frac{\sum_{i=1}^{k} \lambda_i}{\sum_{i=1}^{n} \lambda_i} \cdot 100$$

4. Criteriul analizei paralele

5. Criteriul statistic

F. Matricea factor și interpretare

Este matricea de corelație între variabilele inițiale (X) și componentele principale (Z).

$$\Omega = cor(X, Z) = [Var(X)]^{-\frac{1}{2}} \cdot A \cdot \Lambda^{\frac{1}{2}}$$

Un element al matricii este:

$$\omega_{ij} = \mathrm{cor}(X_i, Z_j) = \frac{\sqrt{\lambda_j}}{\sigma_i} \alpha_i^{(j)}$$

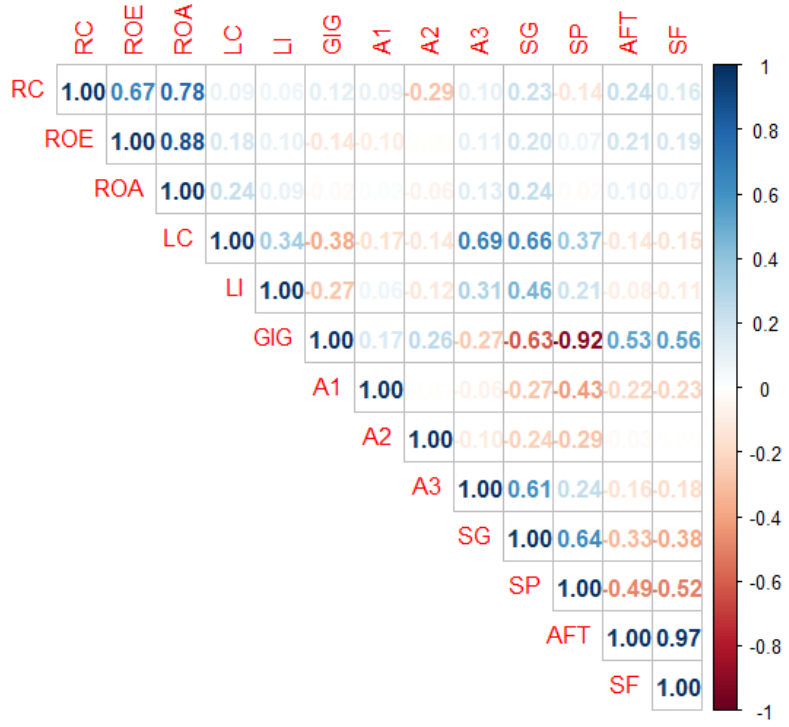
= coeficientul de corelație dintre a i – a variabilă și a j – a componentă principală

Astfel, componentele principale pot fi interpretate în termeni de variabile originale cu care sunt cel mai puternic corelate.

G. Exemplu numeric – set de date cu companii

Notatie	Indicator	Formula
RC	rentabilitatea comerciala	(profit net/cifra de afaceri)*100
ROE	rentabilitate financiara	(profit net/capitaluri proprii)*100
ROA	rentabilitatea economica	(profit net/activ total)*100
LC	lichiditatea curenta	(active circulante-stocuri)/datorii curente
LI	lichiditatea imediata	trezorerie/datorii curente
GIG	grad de indatorare general	(datorii totale/activ total)*100
A1	activitate	cifra de afaceri/active
A2	activitate	furnizori/cifra de afaceri
A3	activitate	clienti/datorii totale
SG	solvabilitate globala	active totale/datorii totale
SP	solvabilitate patrimoniala	capitaluri proprii/active totale
AFT	autonomia financiara la termen	datorii pe termen lung/capitaluri proprii
SF	stabilitate financiara	datorii pe termen lung/(datorii pe termen lung+capitaluri proprii)

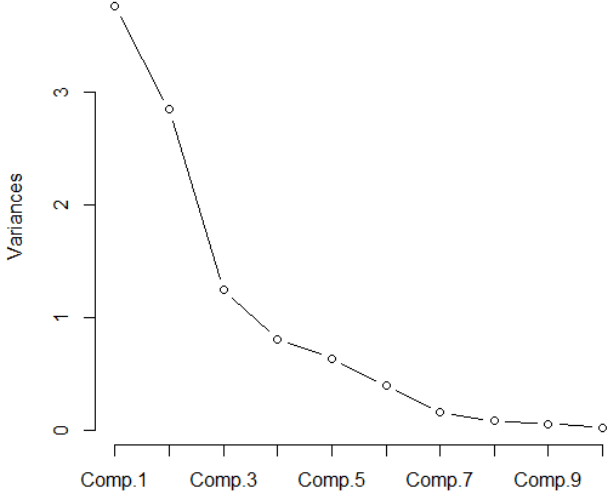
13 variabile, 40 de observatii initial, 34 de observatii dupa eliminarea outlyer-ilor



Variabile eliminate din analiză: A1, A2, A3

Număr componente: 3. Care sunt criteriile utilizate?

```
> acp2$eig
        eigenvalue percentage of variance cumulative percentage of variance
comp 1  3.76030570             37.6030570                            37.60306
comp 2  2.84290427             28.4290427                            66.03210
comp 3  1.24325842             12.4325842                            78.46468
comp 4  0.80434661              8.0434661                            86.50815
comp 5  0.63688703              6.3688703                            92.87702
comp 6  0.39529000              3.9529000                            96.82992
comp 7  0.15789324              1.5789324                            98.40885
comp 8  0.08383330              0.8383330                            99.24719
comp 9  0.05288914              0.5288914                            99.77608
comp 10 0.02239229              0.2239229                           100.00000
```



```
> CV<-cov(scale(X,center=T,scale=T))
> round(eigen(CV)$vectors,3)
       [,1]   [,2]   [,3]   [,4]   [,5]   [,6]   [,7]   [,8]   [,9]  [,10]
 [1,]  0.018 -0.507  0.216 -0.165 -0.015  0.606  0.496  0.165 -0.133 -0.100
 [2,] -0.051 -0.527  0.192  0.183  0.184 -0.422 -0.278  0.350 -0.485  0.041
 [3,] -0.059 -0.539  0.274 -0.079 -0.038 -0.238 -0.081 -0.520  0.538  0.026
 [4,] -0.294 -0.177 -0.416 -0.037 -0.700 -0.318  0.325  0.062 -0.086  0.009
 [5,] -0.214 -0.116 -0.497 -0.574  0.568 -0.147  0.122 -0.063 -0.037 -0.004
 [6,]  0.456 -0.028 -0.003 -0.398 -0.265  0.051 -0.221 -0.479 -0.529  0.040
 [7,] -0.416 -0.173 -0.247 -0.043 -0.171  0.489 -0.678  0.051  0.053 -0.016
 [8,] -0.443  0.049 -0.024  0.475  0.199  0.111  0.194 -0.580 -0.386  0.001
 [9,]  0.368 -0.233 -0.426  0.327  0.088  0.145  0.040 -0.012  0.104  0.694
[10,]  0.384 -0.205 -0.422  0.332  0.074  0.011 -0.043 -0.061  0.079 -0.710
> acp <- princomp(X,cor=T,scores=TRUE)
> acp$loadings

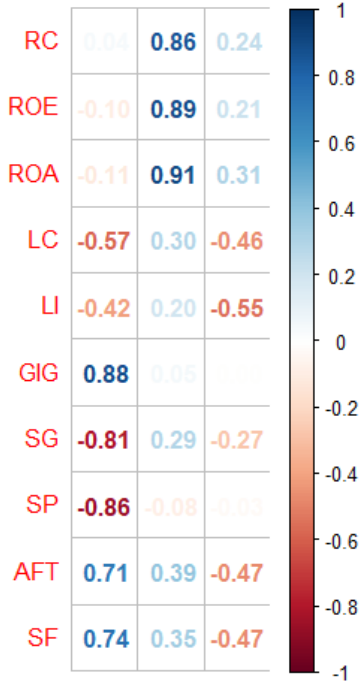
Loadings:
    Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7 Comp.8 Comp.9 Comp.10
RC          0.507  0.216  0.165         0.606  0.496  0.165  0.133
ROE         0.527  0.192 -0.183 -0.184 -0.422 -0.278  0.350  0.485
ROA         0.539  0.274                -0.238        -0.520 -0.538
LC  -0.294  0.177 -0.416         0.700 -0.318  0.325
LI  -0.214  0.116 -0.497  0.574 -0.568 -0.147  0.122
GIG  0.456                 0.398  0.265        -0.221 -0.479  0.529
SG  -0.416  0.173 -0.247         0.171  0.489 -0.678
SP  -0.443                -0.475 -0.199  0.111  0.194 -0.580  0.386
AFT  0.368  0.233 -0.426 -0.327         0.145                -0.104 -0.694
SF   0.384  0.205 -0.422 -0.332                                       0.710
```

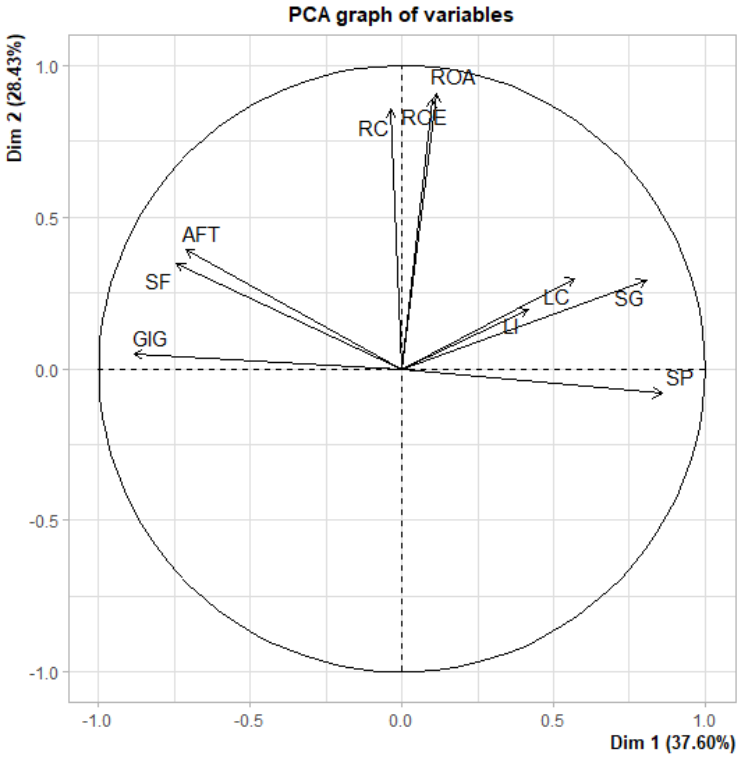
Calcul scoruri principale

```
> round(scale(X,center=T,scale=T)[1:5,],3)
         RC    ROE    ROA     LC     LI    GIG     SG     SP    AFT     SF
AGQR -0.073 -0.757 -0.789 -0.366 -0.364  0.289 -0.686 -0.181 -0.445 -0.539
ACBU -0.629 -0.311 -0.455 -0.448 -0.397 -0.498 -0.391  0.587 -0.445 -0.539
CDRM  0.557  0.604  0.473 -0.556 -0.400  0.926 -0.744 -0.802 -0.445 -0.539
ISCO  0.462  1.333  1.476 -0.367 -0.310 -0.030 -0.626  0.103 -0.445 -0.539
ARTD  0.264  0.464  0.524 -0.332 -0.359 -0.216 -0.568  0.312 -0.445 -0.539
> acp$scores[1:5,1:3]
         Comp.1     Comp.2    Comp.3
AGQR  0.4025650 -1.3040685 0.5531628
ACBU -0.4541292 -1.1958295 0.5725487
CDRM  0.9314085  0.4395554 1.4342971
ISCO -0.1442802  1.3224768 1.6605465
ARTD -0.2499690  0.2304190 1.1739856
```

Nume componente: Z_1 = solvabilitate; Z_2 = rentabilitate; Z_3 = lichiditate

	Comp.1	Comp.2	Comp.3
RC	0.04	**0.86**	0.24
ROE	-0.10	**0.89**	0.21
ROA	-0.11	**0.91**	0.31
LC	**-0.57**	0.30	**-0.46**
LI	**-0.42**	0.20	**-0.55**
GIG	**0.88**	0.05	0.05
SG	**-0.81**	0.29	-0.27
SP	**-0.86**	-0.08	-0.03
AFT	**0.71**	0.39	**-0.47**
SF	**0.74**	0.35	**-0.47**





Output numeric (funcția PCA):

Eigenvalues

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5	Dim.6	Dim.7	Dim.8
Variance	3.760	2.843	1.243	0.804	0.637	0.395	0.158	0.084
% of var.	37.603	28.429	12.433	8.043	6.369	3.953	1.579	0.838
Cumulative % of var.	37.603	66.032	78.465	86.508	92.877	96.830	98.409	99.247

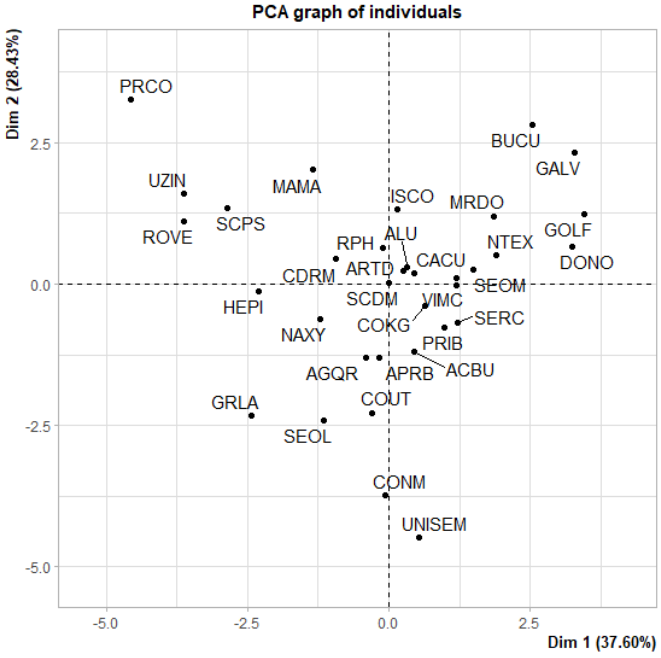
	Dim.9	Dim.10
Variance	0.053	0.022
% of var.	0.529	0.224
Cumulative % of var.	99.776	100.000

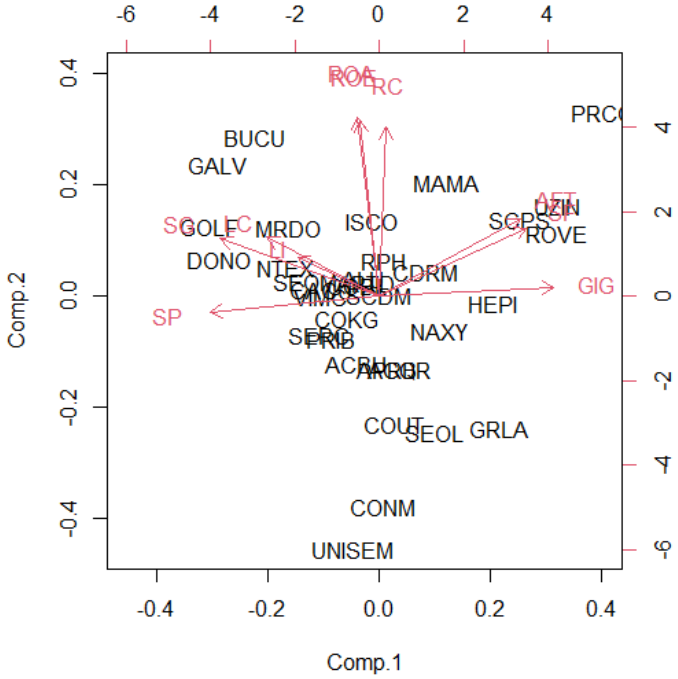
Variables

	Dim.1	ctr	cos2	Dim.2	ctr	cos2	Dim.3	ctr	cos2
RC	-0.035	0.033	0.001	0.855	25.720	0.731	-0.241	4.674	0.058
ROE	0.099	0.263	0.010	0.889	27.798	0.790	-0.214	3.695	0.046
ROA	0.115	0.350	0.013	0.909	29.062	0.826	-0.305	7.501	0.093
LC	0.570	8.649	0.325	0.299	3.137	0.089	0.464	17.316	0.215
LI	0.416	4.594	0.173	0.196	1.348	0.038	0.555	24.750	0.308
GIG	-0.885	20.821	0.783	0.047	0.079	0.002	0.004	0.001	0.000
SG	0.807	17.320	0.651	0.292	3.003	0.085	0.275	6.079	0.076
SP	0.860	19.657	0.739	-0.082	0.236	0.007	0.027	0.060	0.001
AFT	-0.715	13.577	0.511	0.392	5.407	0.154	0.474	18.106	0.225
SF	-0.744	14.737	0.554	0.346	4.210	0.120	0.471	17.818	0.222

OBS: cos2 este pătratul coloanei Dim.j; Suma elementelor pe coloane cos2 este varianța componentei principale (adică valorile λj); Elementele din coloana ctr reprezintă contribuția variabilei la varianța componentei principale (este raportul dintre cos2 și λ).

Output grafic:





! un vector propriu înmulțit cu (-1) este tot vector propriu