ANALIZA DATELOR
Analiza corespondențelor

Facultatea: Cibernetică, statistică și informatică economică
Specializarea: Cibernetică economică
Licență, an 3

Conf. Univ. Dr. Zamfir Ionela-Cătălina
ionela.zamfir@csie.ase.ro

București, 2025

CUPRINS

1. Scop și definiții
2. Tabelul de contingență
3. Metrica χ^2
4. Modelul matematic (cazul a două caracteristici)
5. Exemplu numeric*

1. Scop și definiții

Analiza corespondențelor fost propusă de J. P. Benzecri pentru a studia corelația (corespondența) dintre două variabile calitative.

- Ce sunt variabilele calitative?
- De unde le obținem?
    - Chestionare
    - Transformăm variabilele numerice în calitative

2. Tabelul de contingență

→ rezultă din încrucișarea a două variabile calitative X și Y, una cu m_1 categorii și alta cu m_2 categorii.

X \ Y	y_1	y_2	...	y_j	...	y_{m_2}
x_1	n_{11}	n_{12}	...	n_{1j}	...	n_{1m_2}
x_2	n_{21}					
⋮	⋮					
x_i	n_{i1}			n_{ij}		
⋮	⋮					
x_{m_1}	$n_{m_1 1}$					

Unde n_{ij} este numărul de indivizi care au categoria i pentru variabila X și categoria j pentru variabila Y.

Tabelul de contingență are:

- m_1 linii
- m_2 coloane

Se notează cu n numărul total de indivizi, și se adaugă în tabelul de contingență totalurile pe linii li pe coloane, astfel:

- Totalul pe linii

$$n_{i\cdot} = \sum_{j=1}^{m_2} n_{ij}$$

- Totalul pe coloane

$$n_{\cdot j} = \sum_{i=1}^{m_1} n_{ij}$$

X \ Y	y_1	y_2	...	y_j	...	y_{m_2}	
x_1	n_{11}	n_{12}	...	n_{1j}	...	n_{1m_2}	$n_{1.}$
x_2	n_{21}						$n_{2.}$
⋮	⋮						⋮
x_i	n_{i1}			n_{ij}			$n_{i.}$
⋮	⋮						⋮
x_{m_1}	$n_{m_1 1}$						$n_{m_1.}$
	$n_{.1}$	$n_{.2}$		$n_{\cdot j}$		$n_{\cdot m_2}$	$\boldsymbol{n}$

3. Metrica χ^2

Pe baza valorilor din tabelul de contingență se determină tabelul de frecvențe sau probabilități, astfel:

$$f_{ij} = \frac{n_{ij}}{n}$$

Dacă privim aceste frecvențe drept probabilități bidimensionale

$$f_{ij} = P(Y = y_j, X = x_i)$$

atunci totalurile pe linii $f_{i\cdot}$, respectiv coloane $f_{\cdot j}$, sunt probabilitățile marginale.

Ipoteza de independență sugerează că relația dintre elementele tabelului este:

$$f_{ij} = f_{i\cdot} f_{\cdot j}$$

X \ Y	y_1	y_2	...	y_j	...	y_{m_2}	Masa
x_1	f_{11}	f_{12}	...	f_{1j}	...	f_{1m_2}	f_1
x_2	f_{21}	f_{22}	...	f_{2j}	...	f_{2m_2}	f_2
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	...	$\vdots$	$\vdots$
x_i	f_{i1}	f_{i2}	...	f_{ij}	...	f_{im_2}	f_i
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	...	$\vdots$	$\vdots$
x_{m_1}	$f_{m_1 1}$	$f_{m_1 2}$	...	$f_{m_1 j}$	...	$f_{m_1 m_2}$	$f_{m_1 \cdot}$
Masa	f_1	f_2		f_j		$f_{\cdot m_2}$	**1**

Se determină apoi profilurile pe linii și pe coloane:

Profiluri pe linie

$$f_{i/j} = \frac{n_{ij}}{n_{i\cdot}} = \frac{\frac{n_{ij}}{n}}{\frac{n_{i\cdot}}{n}} = \frac{f_{ij}}{f_{i\cdot}}$$

Profiluri pe coloane

$$f_{j/i} = \frac{n_{ij}}{n_{\cdot j}} = \frac{\frac{n_{ij}}{n}}{\frac{n_{\cdot j}}{n}} = \frac{f_{ij}}{f_{\cdot j}}$$

Testul de independență χ^2 sau test de omogenitate

$$\chi^2 = \sum \frac{(valori\ observate - valori\ așteptate)^2}{valori\ așteptate}$$

Valorile observate sunt frecvențele din tabelul de contingență, iar valorile așteptate sunt frecvențele așteptate în ipoteza de independență (omogenitate). Frecvența așteptată cu f_{ij}^* este $f_{ij}^* = f_{i\cdot}f_{\cdot j}$

Notând n_{ij}^* valoarea așteptată

$$n_{ij}^* = f_{ij}^* n = \frac{n_{i\cdot}n_{\cdot j}}{n}$$

Forma testului poate fi scrisă:

$$\chi^2 = \sum_{i=1}^{m_1}\sum_{j=1}^{m_2} \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*} = \sum_{i=1}^{m_1}\sum_{j=1}^{m_2} \frac{(nf_{ij} - nf_{i\cdot}f_{\cdot j})^2}{nf_{i\cdot}f_{\cdot j}} = \sum_{i=1}^{m_1}\sum_{j=1}^{m_2} n\frac{(f_{ij} - f_{i\cdot}f_{\cdot j})^2}{f_{i\cdot}f_{\cdot j}}$$

H_0: variabilele sunt independente. Statistica construită urmează legea *hi-pătrat* cu un număr de $(m_1 - 1)(m_2 - 1)$ grade de libertate.

Dacă $\chi^2_{calculat} > \chi^2_{(m_1-1)(m_2-1),1-\alpha}$ din tabel $\Rightarrow$ H_0 e respinsă

4. Modelul matematic (cazul a două caracteristici)

În construirea modelului matematic, se pleacă de la profilurile pe linii (L) și pe coloane (C).

Se evidențiează noi factori, care sunt reprezentați de vectorii proprii ai produselor celor două matrice de profile.

$$L \cdot C^T a = \lambda a$$

Vectorii proprii ai matricii $L \cdot C^T$, ordonați după mărimea valorilor proprii corespunzătoare, vor fi factori canonici $\boldsymbol{a}^{(1)}, \boldsymbol{a}^{(2)}, \ldots$.

Prin dualitate, soluțiile ecuației:
$C^T \cdot Lb = \lambda b$

Deci vectorii proprii ai matricei $C^T \cdot L$, ordonați în ordinea (descrescătoare a) valorilor proprii corespunzătoare, vor constitui așa-numiți factori canonici duali $\boldsymbol{b}^{(1)}, \boldsymbol{b}^{(2)}, \ldots$.

Se poate demonstra faptul că ambele ecuații anterioare au soluția $\lambda_0 = 1$. Vectorii proprii corespunzători acesteia vor fi eliminați, reținându-se doar $m_1 - 1$ factori **a**, respectiv $m_2 - 1$ factori **b**.

Există următoarea legătură între componentele factorilor **a** și **b**:

$$b_j = \frac{1}{\sqrt{\lambda}} \sum_{i=1}^{m_1} \frac{n_{ij}}{n_{.j}} a_i \quad \text{și} \quad a_i = \frac{1}{\sqrt{\lambda}} \sum_{i=1}^{m_2} \frac{n_{ij}}{n_{i.}} b_j$$

Pentru 2 factori se reprezintă fiecare categorie *i* a primei caracteristici prin punctul de coordonate $(\sqrt{\lambda}a_i^{(1)}, \sqrt{\lambda}a_i^{(2)})$, iar categoria *j* a celei de-a doua caracteristici prin punctul de coordonate $(\sqrt{\lambda}b_j^{(1)}, \sqrt{\lambda}b_j^{(2)})$.

Apoi se poate determina cât explică fiecare factor din împrăștierea datelor (inerție): $\frac{\lambda_i}{\sum_i \lambda_j} \cdot 100$

5. Exemplu numeric

Calcule în Excel

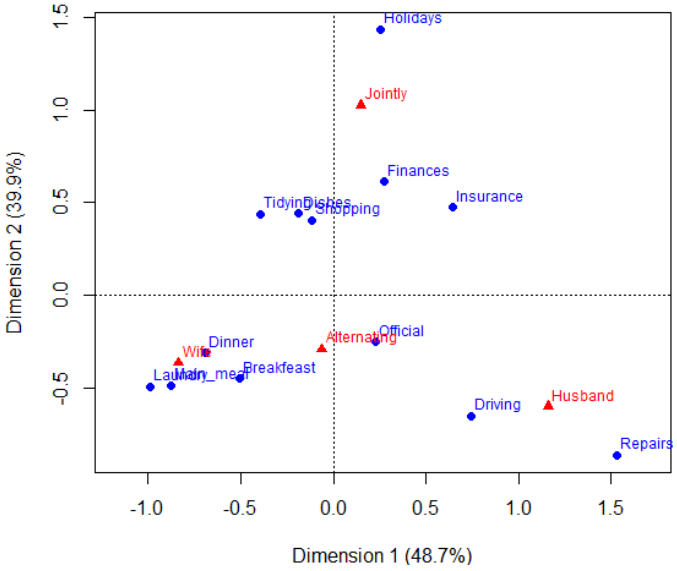
Exemplu – setul de date housetasks din pachetul factoextra

```
> housetasks #din pachetul factoextra
            Wife Alternating Husband Jointly
Laundry      156           14       2       4
Main_meal    124           20       5       4
Dinner        77           11       7      13
Breakfeast    82           36      15       7
Tidying       53           11       1      57
Dishes        32           24       4      53
Shopping      33           23       9      55
Official      12           46      23      15
Driving       10           51      75       3
Finances      13           13      21      66
Insurance      8            1      53      77
Repairs        0            3     160       2
Holidays       0            1       6     153
```

```
> chisq <- chisq.test(housetasks)
> chisq

        Pearson's Chi-squared test

data:  housetasks
X-squared = 1944.5, df = 36, p-value < 2.2e-16
```



Principal inertias (eigenvalues):

dim	value	%	cum%	scree plot
1	0.542889	48.7	48.7	**********
2	0.445003	39.9	88.6	**********
3	0.127048	11.4	100.0	***
	--------	-----		
Total:	1.114940	100.0		

Rows:

	name	mass	qlt	inr	k=1	cor	ctr	k=2	cor	ctr
1	Lndr	101	925	120	-992	740	183	-495	185	56
2	Mn_m	88	974	81	-876	742	124	-490	232	47
3	Dnnr	62	930	34	-693	777	55	-308	154	13
4	Brkf	80	905	37	-509	505	38	-453	400	37
5	Tdyn	70	975	22	-394	440	20	434	535	30
6	Dshs	65	764	18	-189	118	4	442	646	28
7	Shpp	69	811	13	-118	64	2	403	748	25
8	Offc	55	119	48	227	53	5	-254	66	8
9	Drvn	80	767	91	742	432	81	-653	335	76
10	Fnnc	65	997	27	271	161	9	618	837	56
11	Insr	80	885	52	647	576	61	474	309	40
12	Rprs	95	933	281	1529	707	407	-864	226	159
13	Hldy	92	992	176	252	30	11	1435	962	425

Columns:

	name	mass	qlt	inr	k=1	cor	ctr	k=2	cor	ctr
1	Wife	344	954	270	-838	802	445	-365	152	103
2	Altr	146	110	106	-62	5	1	-292	105	28
3	Hsbn	218	980	342	1161	772	542	-602	208	178
4	Jntl	292	998	282	149	21	12	1027	977	691

```
#Cod R – exemplu (housetasks)
#install.packages("factoextra")
library(factoextra)
#install.packages("ca")
library(ca)
housetasks #din pachetul factoextra
chisq <- chisq.test(housetasks)
chisq
dim(housetasks)
ac <- ca(housetasks)
plot(ac)
summary(ac)
```