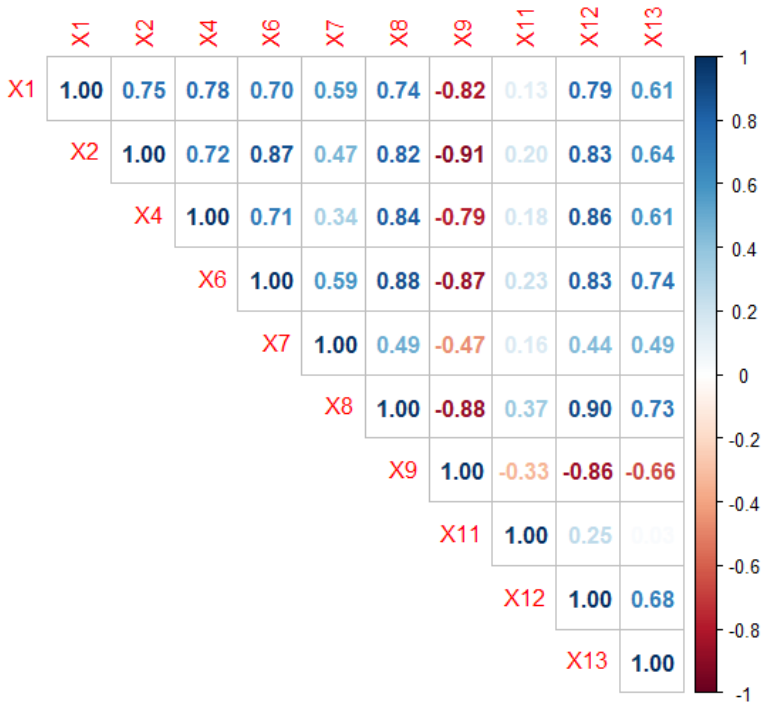
Seminarii 4-5

Obiectiv: analiza performanței în digitalizare la nivel regional.

Se pornește de la matricea de date X (din care am eliminat seminarul anterior 3 variabile), care conține următoarele coloane, pentru 179 de regiuni:

indicator	denumire	u.m.
X1	Individuals who accessed the internet away from home or work	%
X2	Households with access to the internet at home	%
X4	Internet use (public authorities): submitting completed forms (last 12 months)	%
X6	Frequency of internet access: daily	%
X7	Internet use: participating in social networks (creating user profile, posting messages or other contributions to facebook, twitter, etc.)	%
X8	Internet use: Internet banking	%
X9	Internet use: never	%
X11	Last online purchase: between 3 and 12 months ago	%
X12	Online purchases: travel and holiday accommodation	%
X13	Online purchases: from sellers from other EU countries	%

Matricea de corelație este:



Se reiau pașii 5-8 din seminarul anterior, cu argumentul cor=TRUE în funcția princomp()

Argumentul cor=T duce la realizarea ACP pe date standardizate.

- → Ce sunt datele standardizate?
- → Care sunt motivele pentru care se recomandă standardizarea datelor?
- → Ce sunt variabilele standardizate și ce proprietăți au?

5. Folosiți funcția princomp() in R

acp <- princomp(X,cor=**T**,scores=TRUE)

summary(acp)

```
> summary(acp)
Importance of components:
                          Comp.1    Comp.2     Comp.3     Comp.4    Comp.5
Standard deviation     2.620727 1.0116644 0.88342927 0.67722188 0.5996658
Proportion of Variance 0.686821 0.1023465 0.07804473 0.04586295 0.0359599
Cumulative Proportion  0.686821 0.7891675 0.86721226 0.91307521 0.9490351
                           Comp.6     Comp.7      Comp.8      Comp.9     Comp.10
Standard deviation     0.45962933 0.32855638 0.290650571 0.244843896 0.214509243
Proportion of Variance 0.02112591 0.01079493 0.008447775 0.005994853 0.004601422
Cumulative Proportion  0.97016102 0.98095595 0.989403725 0.995398578 1.000000000
```

Se observă că primele 2 componente principale sintetizează împreună 78.91% din informația totală din cele 10 variabile inițiale.

6. Care este legătura dintre valorile cu abaterile standard de mai sus și valorile Lambda?

```
> sqrt(Lambda2)
 [1] 2.6207271 1.0116644 0.8834293 0.6772219 0.5996658 0.4596293 0.3285564
 [8] 0.2906506 0.2448439 0.2145092
```

Valorile proprii ale matricei de covarianță sunt variațele componentelor principale.

7. Ce sunt loadings? Comparati cu V? Ce observati?

acp$loadings

round(E2$vectors,3)

! Un vector propriu înmulțit cu o constantă (de exemplu: -1) este tot vector propriu.

```
> acp$loadings

Loadings:
    Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7 Comp.8 Comp.9 Comp.10
X1   0.330  0.141         0.562  0.189  0.516  0.175  0.279         0.373
X2   0.346                      -0.604  0.125        -0.609 -0.164  0.298
X4   0.328        -0.350  0.266  0.443 -0.301 -0.543 -0.265  0.216
X6   0.354               -0.273 -0.338 -0.282 -0.120  0.464  0.532  0.289
X7   0.228  0.111  0.873  0.173        -0.252        -0.183        -0.178
X8   0.361 -0.120        -0.169  0.125 -0.294         0.321 -0.761  0.183
X9  -0.360         0.106         0.299 -0.300  0.206 -0.248         0.745
X11  0.108 -0.926  0.156         0.156  0.179        -0.104  0.137  0.104
X12  0.356        -0.207         0.103 -0.299  0.781 -0.167  0.183 -0.238
X13  0.297  0.289        -0.678  0.379  0.432        -0.172

               Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7 Comp.8 Comp.9
SS loadings       1.0    1.0    1.0    1.0    1.0    1.0    1.0    1.0    1.0
Proportion Var    0.1    0.1    0.1    0.1    0.1    0.1    0.1    0.1    0.1
Cumulative Var    0.1    0.2    0.3    0.4    0.5    0.6    0.7    0.8    0.9
               Comp.10
SS loadings        1.0
Proportion Var     0.1
Cumulative Var     1.0
> round(E2$vectors,3)
        [,1]   [,2]   [,3]   [,4]   [,5]   [,6]   [,7]   [,8]   [,9]  [,10]
 [1,] -0.330 -0.141  0.067  0.562  0.189  0.516 -0.175  0.279 -0.038  0.373
 [2,] -0.346 -0.023 -0.093  0.025 -0.604  0.125  0.057 -0.609  0.164  0.298
 [3,] -0.328 -0.027 -0.350  0.266  0.443 -0.301  0.543 -0.265 -0.216 -0.016
 [4,] -0.354 -0.032  0.093 -0.273 -0.338 -0.282  0.120  0.464 -0.532  0.289
 [5,] -0.228 -0.111  0.873  0.173  0.075 -0.252  0.064 -0.183  0.066 -0.178
 [6,] -0.361  0.120 -0.095 -0.169  0.125 -0.294  0.009  0.321  0.761  0.183
 [7,]  0.360 -0.098  0.106 -0.091  0.299 -0.300 -0.206 -0.248 -0.058  0.745
 [8,] -0.108  0.926  0.156 -0.095  0.156  0.179 -0.001 -0.104 -0.137  0.104
 [9,] -0.356  0.018 -0.207  0.045  0.103 -0.299 -0.781 -0.167 -0.183 -0.238
[10,] -0.297 -0.289  0.075 -0.678  0.379  0.432  0.012 -0.172 -0.054 -0.024
```

8. Ce reprezintă scores? Ce dimensiune are matricea scoruri?

scoruri <- acp$scores

dim(scoruri)

```
> dim(scoruri)
[1] 179  10
```

coef <- acp$loadings

Ponderare2 <- scale(X,center=T,scale=T) %*% coef

round(scoruri,3)[1:5,] #afisez doar primele 5 regiuni

round(Ponderare2,3)[1:5,] #afisez doar primele 5 regiuni

```
> print(acp)
Call:
princomp(x = X, cor = T, scores = TRUE)

Standard deviations:
   Comp.1    Comp.2    Comp.3    Comp.4    Comp.5    Comp.6    Comp.7    Comp.8
2.6207271 1.0116644 0.8834293 0.6772219 0.5996658 0.4596293 0.3285564 0.2906506
   Comp.9   Comp.10
0.2448439 0.2145092

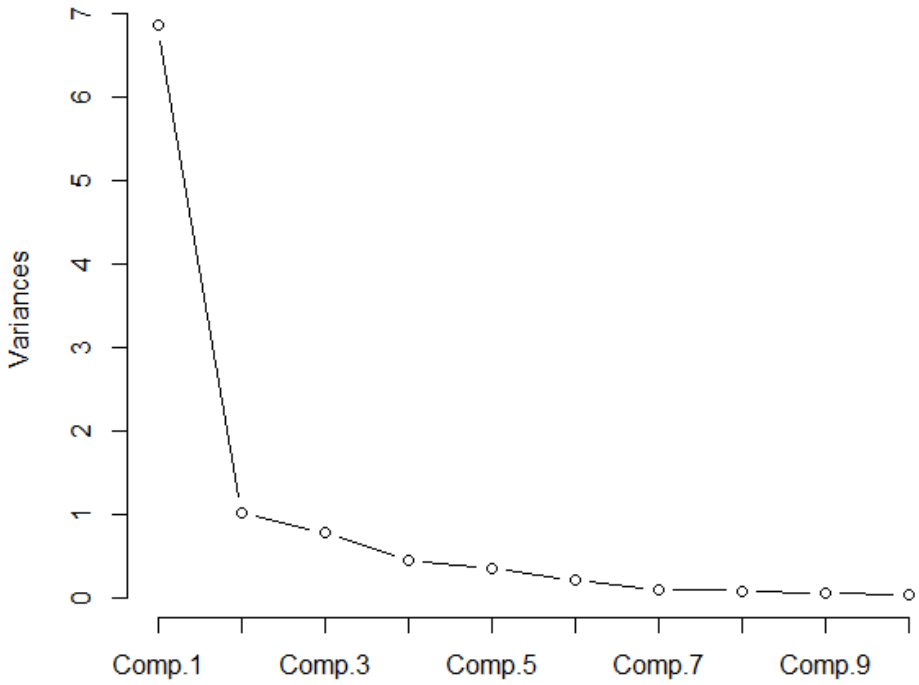
 10  variables and  179 observations.
```

Concluzie: se construiesc inițial 10 combinații liniare (componente principale), care au ca variațele valorile proprii ale matricei de covariață.

Care sunt proprietățile componentelor principale?

```
> Lambda2
 [1] 6.86821048 1.02346483 0.78044727 0.45862948 0.35959902 0.21125912 0.10794930 0.08447775
 [9] 0.05994853 0.04601422
> sum(Lambda2)
[1] 10
> round(cor(scoruri),7)
        Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7 Comp.8 Comp.9 Comp.10
Comp.1       1      0      0      0      0      0      0      0      0       0
Comp.2       0      1      0      0      0      0      0      0      0       0
Comp.3       0      0      1      0      0      0      0      0      0       0
Comp.4       0      0      0      1      0      0      0      0      0       0
Comp.5       0      0      0      0      1      0      0      0      0       0
Comp.6       0      0      0      0      0      1      0      0      0       0
Comp.7       0      0      0      0      0      0      1      0      0       0
Comp.8       0      0      0      0      0      0      0      1      0       0
Comp.9       0      0      0      0      0      0      0      0      1       0
Comp.10      0      0      0      0      0      0      0      0      0       1
```

Care sunt criteriile de alegere a numărului de componente?




```
> summary(acp)
Importance of components:
                          Comp.1    Comp.2     Comp.3     Comp.4    Comp.5     Comp.6     Comp.7
Standard deviation     2.620727 1.0116644 0.88342927 0.67722188 0.5996658 0.45962933 0.32855638
Proportion of Variance 0.686821 0.1023465 0.07804473 0.04586295 0.0359599 0.02112591 0.01079493
Cumulative Proportion  0.686821 0.7891675 0.86721226 0.91307521 0.9490351 0.97016102 0.98095595
                           Comp.8      Comp.9     Comp.10
Standard deviation     0.290650571 0.244843896 0.214509243
Proportion of Variance 0.008447775 0.005994853 0.004601422
Cumulative Proportion  0.989403725 0.995398578 1.000000000
```

Concluzie: se vor păstra primele 2 componente principale.

Matricea factor (matricea de corelație dintre variabile inițiale și componente principale):

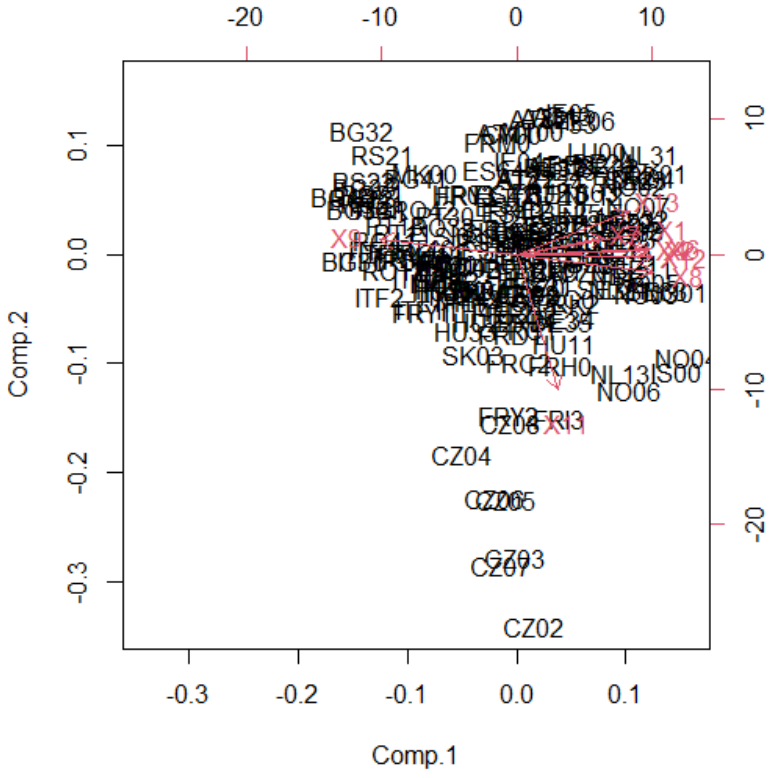
MF=cor(X,scoruri)

```
> MF
        Comp.1      Comp.2      Comp.3      Comp.4      Comp.5
X1   0.8635332  0.14232001  0.05946386  0.38092001  0.11354744
X2   0.9057769  0.02277679 -0.08255184  0.01688823 -0.36231616
X4   0.8608445  0.02767063 -0.30909602  0.18043695  0.26537861
X6   0.9270360  0.03270197  0.08182940 -0.18514935 -0.20293832
X7   0.5983045  0.11225021  0.77149111  0.11718055  0.04525712
X8   0.9466533 -0.12179881 -0.08406407 -0.11467761  0.07472644
X9  -0.9439471  0.09911007  0.09377028 -0.06133971  0.17911167
X11  0.2842635 -0.93697811  0.13812390 -0.06411867  0.09342396
X12  0.9326437 -0.01822898 -0.18270555  0.03020612  0.06196675
X13  0.7783657  0.29212643  0.06589707 -0.45906211  0.22702881
```

Prima componentă principală Z1 se corelează puternic cu majoritatea variabilelor (mai puțin X11), și sintetizează **nivelul de digitalizare** la nivel regional în Europa, iar a doua componentă principală (Z2) sintetizează **utilizarea internetului cu mai mult de 3 luni în urmă** (dar mai puțin de 12 luni) **pentru cumpărături online**. Coeficientul de corelație dintre X11 și Z2 este negativ, iar în analiza regiunilor trebuie să se țină cont de semnul acestuia.

Reprezentarea regiunilor în spațiu cu două dimensiuni:

biplot(acp)



Temă:

1. Instalați cele două biblioteci:

install.packages("factoextra")

install.packages("FactoMineR")

library(factoextra)

library(FactoMineR)

2. Folosiți funcția PCA() pentru a realiza analiza componentelor principale.

acp2 <- PCA()

3. Extrageți outputurile folosind următoarele funcții:

✓ summary(acp2)

✓ fviz_eig(acp2)

✓ fviz_pca_ind(acp2)

✓ fviz_pca_var(acp2,col.var="contrib")

4. Comparați output-urile funcțiilor PRINCOMP() și PCA().